

elasticsearch



Pawel Kowalski & Marco Schmalz
iterativ.ch

Sept 2016

Use Cases für elastic

Custom search engine (-toolbox)

- e-Commerce
- Suche in Webapps
 - Leute, Events, Produkte suchen

Event-store für Sysadmins, Security Monitoring

- Zusammen mit Kibana - vergleichbar mit Splunk

NoSQL Datenbank

- elastic ist auch einfach eine NoSQL DB für json Dokumente

Information Retrieval



Information Retrieval

- Produkte, Leute, Events, alles sind json Dokumente in elasticsearch
- Ziel ist mit queries die richtigen Dokumente aus elastic herauszuholen
- Das ist 'Information Retrieval'

Theorie

- Information Retrieval
- Text Analyse - Normalisierung
 - Normalisierung
 - Synonyme
- Recall und Precision

Theorie & Themen

Information Retrieval

- TF/IDF
 - Term Frequency
 - Inverse Document Frequency
- Precision / Recall
- Normalisierung für den Vergleich
 - Tokenizing
 - Lowercase
 - Stemming
 - Soundex
 - Stopwords (to be or not to be)
 - Decomposition (für Deutsch)
 - Synonyme

Implementation

- Querying
- Inverted Index
 - Was ist das? Ihr kennt das alle: jmd aus dem Publikum ausspicken
- Aggregations

UX

- Universelle Suche: über alle Felder

TF / IDF

- Term Frequency / Inverse Document Frequency

Term Frequency:

$$TF(t) = \frac{\text{(Häufigkeit des Begriffs } t \text{ im Dokument)}}{\text{(Anzahl Wörter im Dokument)}}$$

Inverse Document Frequency:

$$IDF(t) = \log_e \left(\frac{\text{Anzahl der Dokumente}}{\text{Anzahl der Dokumente mit dem Begriff } t}} \right)$$


Precision & Recall

Precision:

$$\text{Precision} = \frac{tp}{tp + fp}$$

Recall:


$$\text{Recall} = \frac{tp}{tp + fn}$$



How many selected items are relevant?



How many relevant items are selected?



Normalisierung - Vergleichbarkeit

Damit die Texte verglichen und gefunden werden können:

Es braucht eine Grundform. Ansonsten würde der Index mit den verschiedenen Formen riesig, oder wir hätten sehr viele Vergleiche

- Tokenizing - Text in tokens aufsplitten
- Stemming - Stammformen der Wörter
- Stopwords - wie, auch, und, etc.. tragen *nicht* zur Information bei..
- Decomposition - Zusammengesetzte Wörter auf Deutsch
- Synonyme - Bürosessel vs. Bürostuhl

Normalisierung - Vergleichbarkeit

Query: *Suche spannende Routen zum Wandern oder **Velofahren***

tokens: ['Suche', 'spannende', 'Routen', 'zum', 'Wandern', 'oder', '**Velofahren**']

lower: ['suche', 'spannende', 'routen', 'zum', 'wandern', 'oder', '**velofahren**']

stop: ['suche', 'spannende', 'routen', 'wandern', '**velofahren**']

stem: ['such', 'spannend', 'rout', 'wander', '**velofahr**']

decomp: ['such', 'spannend', 'rout', 'wander', '**velofahr**', '**velo**', '**fahr**']

synonyme: ['such', 'spannend', 'rout', 'wander', '**velofahr**', '**velo**', '**bike**', '**fahr**']

Normalisierung - Vergleichbarkeit

Query: *‘Suche spannende Routen **zum** Wandern oder Velofahren’*

tokens: [‘Suche’, ‘spannende’, ‘Routen’, **‘zum’**, ‘Wandern’, ‘oder’, ‘Velofahren’]

lower: [‘suche’, ‘spannende’, ‘routen’, **‘zum’**, ‘wandern’, ‘oder’, ‘velofahren’]

stop: [‘suche’, ‘spannende’, ‘routen’, ‘wandern’, ‘velofahren’]

stem: [‘such’, ‘spannend’, ‘rout’, ‘wander’, ‘velofahr’]

decomp: [‘such’, ‘spannend’, ‘rout’, ‘wander’, ‘velofahr’, ‘velo’, ‘fahr’]

synonyme: [‘such’, ‘spannend’, ‘rout’, ‘wander’, ‘velofahr’, ‘velo’, ‘bike’, ‘fahr’]

Decomposition

Guter Beispiel zu dem wann die Normalisierung passiert

| | |
|-------------------|--|
| Zur Index-Zeit: | Beim indexieren wird der text normalisiert |
| Zur Abfrage-Zeit: | Beim abfragen wird die query normalisiert |

Klobürste - Zahnbürste ⇒ ['klo', 'bürste'], ['zahn', 'bürste']

Deshalb:

| | | | |
|-------------|---------------------|---|---|
| Index-Zeit: | Decomposition | ⇒ | [0:'zahn', 1:'bürste', 2:'zahnbürste'] |
| Abfrage: | Keine Decomposition | ⇒ | |
| | 'Zahnbürste' | ⇒ | match mit 2:' <i>zahnbürste</i> ' |
| | 'Zahn bürste' | ⇒ | match mit 0:' <i>zahn</i> ' und 1:' <i>bürste</i> ' |
| | 'Bürste' | ⇒ | match mit 1:' <i>bürste</i> ' d.h. Klob <i>ürste</i> und Zahn <i>bürste</i> |

Decomposition

Verschiedene Ansätze wie die Decomposition implementiert werden kann:

- Dictionary basiert
- The elasticsearch decomposer uses prebuilt Compact Patricia Tries

Teleobjektiv ⇒ [‘tele’, ‘objektiv’]

Telezoomobjektiv ⇒ [‘tele’, ‘zoom’ ‘objektiv’]

Urinstinkt ⇒ [‘ur’, ‘instinkt’] oder [‘urin’, ‘stinkt’]

Synonyme

- Expansion

| | | | |
|--------------|---------|---------|-----|
| Velo | Fahrrad | Bike | MTB |
| Lautsprecher | Boxen | Speaker | |

- Canonical Form

| | | | | |
|----------|---------|-------------|---|--------|
| Notebook | Laptop | Portable PC | ⇒ | Laptop |
| Velo | Fahrrad | Bike | | Velo |

Bei der 'Canonical Form' können Kollisionen mit anderen Begriffen vermieden werden wie zB. 'Portable PC' ⇒ Natel aka. 'Portable'

Abfragen

Dokumente können relativ komplexe JSON Strukturen sein.

[TODO]

Signals Konzept

Scoring: `_score`

`_all` Field and `copy_fields`

Inverted Index


| ID | Text |
|----|------|
|----|------|

- | | |
|---|---|
| 1 | Schwimmen wir auch im Winter in der Aare? |
| 2 | Im Winter sind wir in Silvaplana |
| 3 | Aare ist wunderbar |



Dokumente:

Inverted Index:



| Term | Freq | Document IDs |
|------------|------|--------------|
| schwimmen | 1 | [1] |
| wir | 1 | [1] [2] |
| auch | 1 | [1] |
| im | 2 | [1] [2] |
| winter | 2 | [1] [2] |
| in | 2 | [1] [2] |
| der | 1 | [1] |
| aare | 2 | [1] [3] |
| sind | 1 | [2] |
| silvaplana | 1 | [2] |
| wunderbar | 1 | [3] |

Aggregationen

- Sind sehr schnell (siehe Inverted Index)
- Können auch geschachtelt sein
 - zB Altersstruktur pro Stadt
- Früher wurde das 'Facettensuche' genannt
 - zB. Bei Suche der Leute:
 - Stadt
 - Alter


Typen:

- Terms, Histogramm, Geo, Dates, Significant Terms
 - <https://www.elastic.co/blog/significant-terms-aggregation>

Aggregationen

KATEGORIEN

- Aftershave & Rasurpflege (12)
- Body Lotion & Body Butter (5)
- Business Schuhe (26)
- Champagner & Schaumwein (1)
- Deo & Antitranspirant (10)
- Duschgel & Duschschaum (8)
- Körperpflegeset (15)
- Parfum (73)
- Rotwein (6)
- Schul- & Lernbücher (2)
- Süsswein (1)
- Weisswein (1)



Ergebnisse für «lego»

Preis



CHF 0.00 - 20.00
CHF 20.00 - 50.00
CHF 50.00 - 100.00
CHF 100.00 - 200.00

Marke



Händler



UX - Universelle Suche

MyService CRM

Suchen

Neukunde erfassen

Kunde importieren

Suchen

🔍 Suchen

Nach Name, BSK-Nummer, Telefon, Firma und Ort

siroop.ch

Wonach suchst du?



UX - Universelle Suche - nooot!

Praktischer einsatz


Server

localhost:9200

```
1 POST /multiwords/words/1
2 {
3   "text": "tele objektiv in da house"
4 }
5
6 POST /multiwords/_search
7 {
8   "query": {
9     "dis_max": {
10      "tie_breaker": 0.7,
11      "boost": 1.2,
12      "queries": []
13    }
14   }
15 }
16 }
17
```

```
1 {
2   "count": 61958,
3   "_shards": {
4     "total": 5,
5     "successful": 5,
6     "failed": 0
7   }
8 }
```

Praktischer einsatz



Sense (Beta)

offered by cheics

★★★★★ (133) [Developer Tools](#) 70,336 users

OVERVIEW

REVIEWS

SUPPORT

RELATED

ADDED TO CHROME

X

G+1

33

Server: 192.168.231.50:9200/telemetry-dev

History Help

```
6 GET _search
7 {
8   // All events actually have a doctype
9   query:{
10     "term":{"doctype":"event"}
11   }
12 }
13 GET _search
14 {
15   "took": 2,
16   "timed_out": false,
17   "_shards": {
18     "total": 5,
19     "successful": 5,
20     "failed": 0
21   },
22   "hits": {
23     "total": 128560,
24     "max_score": 0.99996144,
25     "hits": [
26       {
27         "_index": "telemetry-dev",
28         "_type": "event",
29         "_id": "924148433984d17fbb3831acc251f1d4",
30         "_score": 0.99996144,
31         "_source": {
32           "_rev": "1-2372ccb8e867563e4386da7aac230c43",
33           "appId": "a1fwUmay0V00eZbwRowk49MbyU4u6e10",
34           "doctype": "event",
35           "_id": "924148433984d17fbb3831acc251f1d4",
36           "event": {
37             "ts": 1407402918,
38             "Type": "ValidateAccessTokenTelemetryEvent",
39             "IpAddress": "157.56.164.154",
40             "UserIdOnToken": "3bc32978bebe4456ab37def"
```

explain

facets

partial_fields

search_type

stats

Users: {

natlity: {

field: "k2"

Owen was using this to determine number of unique users... K2 cannot be used this way. It often has a value of // things like "landscape"

// We get 49 users here

Compatible with your device

A JSON aware developer console to Elasticsearch.

Unofficial!

Forked from <https://github.com/bleskes/sense>, which is no longer present in the Chrome Extension Store

Now maintained (or not really maintained) here: <https://github.com/cheics/sense>

Report Abuse

Additional Information

Version: 0.9.0

Praktischer einsatz

Dokument-Suche

- Indexierung
- Querying
- Aggregationen
- Suggestions

Betriebliche & Setup-Aspekte

- Mappings
- Zero Downtime mapping-Änderungen: <http://elastic.iterativ.ch>
- Backups vs. MasterDB

Praktischer einsatz

Dokument-Suche

- Indexierung
- Querying
- Aggregationen
- Suggestions

Betriebliche & Setup-Aspekte

- Mappings
- Zero Downtime mapping-Änderungen
- Backups vs. MasterDB

Praktischer einsatz

Praktischer einsatz

Spannende Themen - Beyond elastic



Spannende Themen - Beyond elastic

Feedback Loop aus dem Benutzerverhalten - **alle Interaktionen loggen!**

(auch wenn es nicht klar ist, wie die Daten ausgewertet werden):

```
{
  "date_time": "2016-01-31 14:58:40",
  "session_number": 1,
  "source": {
    "q": "iphone",
    "category": "Handy",
    "page": "1"
  },
  "sink": {
    "q": "iphone 6s",
    "page": "1"
  },
  "device_id": "56addb26b49e12.74785018"
}
```

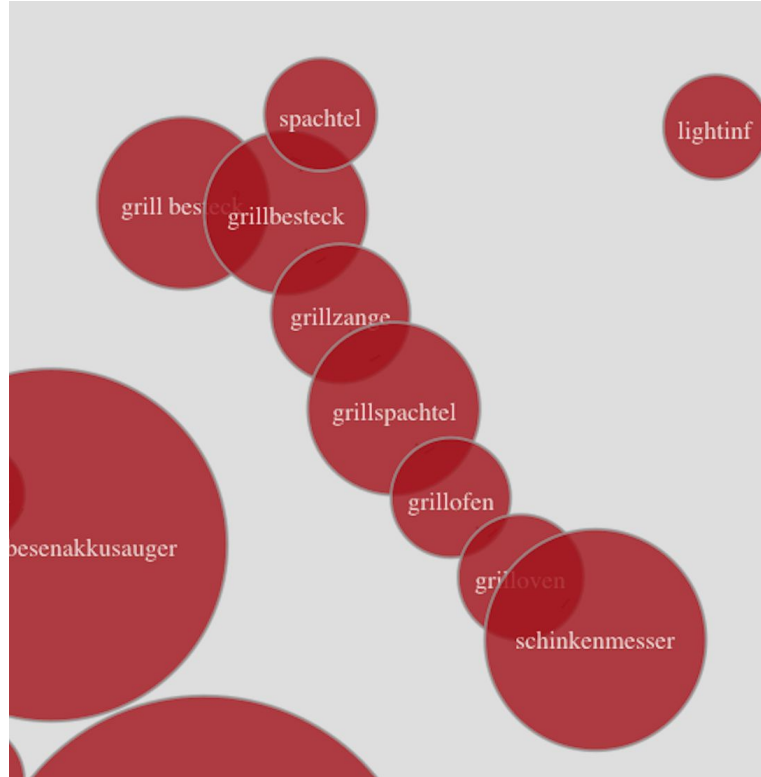
```
{
  "date_time": "2016-01-31 08:22:30",
  "session_number": 0,
  "source": {
    "q": "ipad mini",
    "category": "Tablet",
    "brand_name": "Apple",
  },
  "sink": {
    "q": "ipad mini",
    "category": "Tablet",
    "brand_name": "Apple",
    "sort": "price",
  },
  "device_id": "56adc4417ee674.11822684"
}
```

Spannende Themen - Beyond elastic

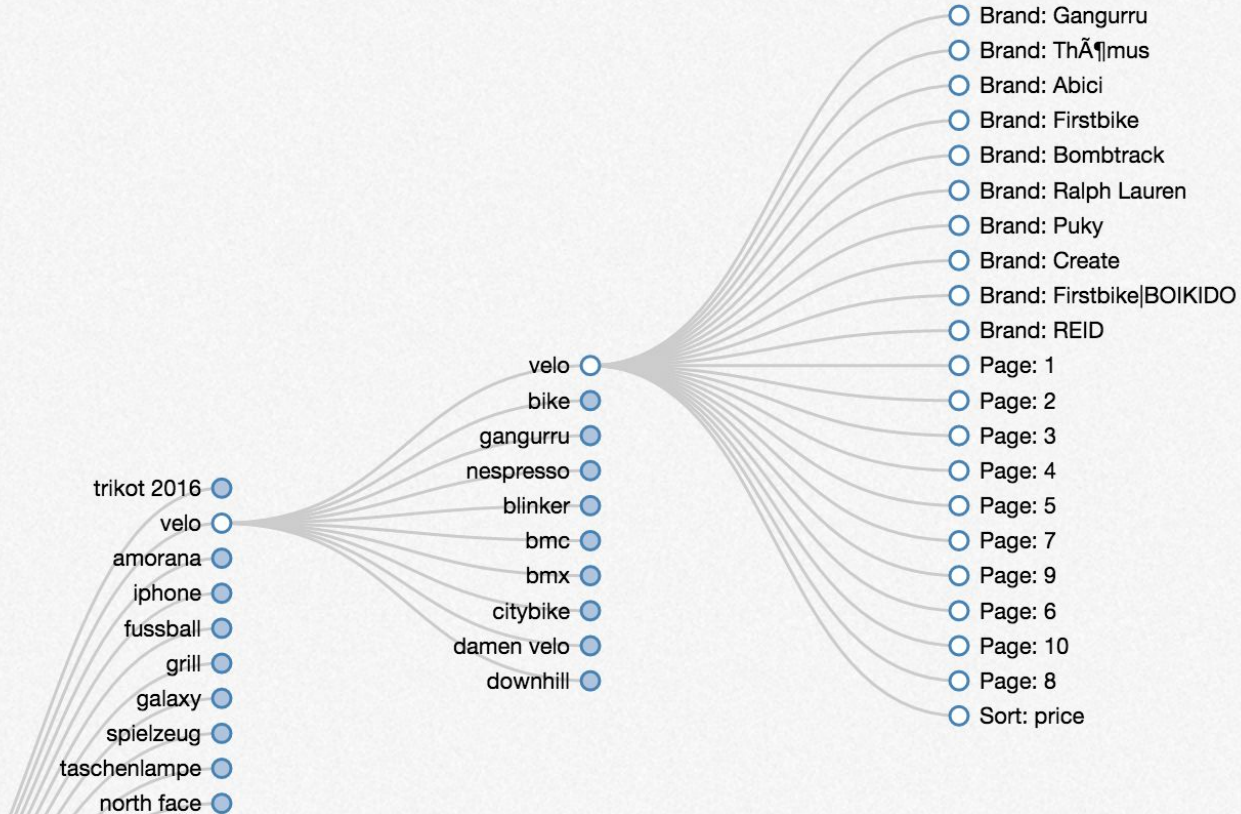
Was machen wir mit diesen Daten?

- Term - Pfade
 - Lego - Lego Technic - Arocs - [produkt]
- Synonyme
 - Bürosessel - Bürostuhl
- Wahrscheinlichkeit für den nächsten Begriff
 - Grillzange - Grillgabel - Grillbesteck

Spannende Themen - Beyond elastic



Spannende Themen - Beyond elastic



Spannende Themen - Beyond elastic

Input Preprocessing:

Ich suche Mammut Hiking Ausrüstung für den Herbst

Named Entity Annotation:

| | | |
|--|-----------------|-------------------|
| Brand | Category | Jahreszeit |
| ↓ | ↓ | ↓ |
| <i>Ich suche Mammut Hiking Ausrüstung für den Herbst</i> | | |

https://en.wikipedia.org/wiki/Named-entity_recognition

Fazit

- Elasticsearch kann sehr vielseitig eingesetzt werden
- Es ist aber wie eine Toolbox
 - Die gute Lösung muss engineered werden
- Gute Suche ist **nicht nur** mit Textvergleichen gemacht
 - Kann erst mit der Analyse des **Benutzerverhaltens** erreicht werden
- SearchKit - super Framework für einen Datenexplorer!
 - <http://searchkit.co/>
- Mit Kibana ein Super Tool für die Visualisierung von Timestamped-Daten

Merci fürds zuelose!



Pawel & Marco

pawel.kowalski@iterativ.ch

marco@schess.ch